

# Отчёт по анализу алкогольной зависимости у студентов


## Описание данных

Датасет взят [отсюда](#). Исследуемый датасет содержит информацию о 395 студентах и включает следующие ключевые переменные:

- **Демографические данные:** пол, возраст, адрес, размер семьи, статус родителей
- **Семейные факторы:** образование родителей, профессии, отношения в семье
- **Академические показатели:** оценки (G1, G2, G3), время учебы, пропуски
- **Потребление алкоголя:** будни (Dalc) и выходные (Walc)
- **Дополнительные переменные:** хобби, интернет, отношения и др.

Созданы производные переменные:

- $G = G1 + G2 + G3$  (суммарная оценка)
- $Salc = Dalc + Walc$  (суммарное потребление алкоголя в неделю)



## Предварительный анализ данных

Распределение ключевых переменных


**Демография:**

- Пол: 208 женщин (52.7%), 187 мужчин (47.3%)
- Размер семьи: GT3 (281), LE3 (114)
- Статус родителей: живут вместе (354), отдельно (41)

### **Алкогольное потребление:**


- Распределение Salc похоже на экспоненциальное
- Потребление выше на выходных по сравнению с буднями

### **Картичонки:**




### **Проверка нормальности распределения оценок**

**Метод пристального взгляда:** похоже



Хотя левый хвост облегчен, а правый утяжелён:



- Среднее: 32.04, стандартное отклонение: 11.09

- Правило трёх сигм выполняется:
  - $\pm 1\sigma$ : 68.4% данных (ожидается 68.3%)
  - $\pm 2\sigma$ : 95.9% данных (ожидается 95.4%)
  - $\pm 3\sigma$ : 100% данных (ожидается 99.7%)

### Статистические тесты нормальности:

- Тест Шапиро-Уилка:  $p\text{-value} = 0.0505 > 0.05$
- Тест D'Agostino:  $p\text{-value} = 0.1578 > 0.05$

Оба теста не отвергают гипотезу о нормальном распределении.

## Статистические гипотезы

### 1. Влияние статуса родителей на потребление алкоголя

#### Гипотезы:

- $H_0: E(Salc|T) = E(Salc|A)$  (нет различий)
- $H_1: E(Salc|T) \leq E(Salc|A)$  (дети разведенных родителей пьют больше)

**Метод:** Тест Манна-Уитни (распределение не нормальное)

#### Результаты:

- Вместе: среднее = 3.77, ст.откл. = 1.94
- Отдельно: среднее = 3.83, ст.откл. = 2.35
- $p\text{-value} = 0.7111$

**Вывод:** Нет статистически значимых различий ( $p > 0.05$ ). Принимаем  $H_0$ .

### 2. Влияние алкоголя на успеваемость

#### Корреляционный анализ:

- Корреляция Salc и G: -0.089676

#### Сравнение групп:


- Высокое потребление vs низкое потребление
- t-test p-value: 0.1286

**Вывод:** Нет статистически значимых различий в успеваемости.

### 3. Гендерные различия в потреблении алкоголя

**Гипотезы:** Мужчины пьют больше женщин

**Метод:** Пристального взгляда на барплот:



**Вывод:** Мужчины пьют побольше.

## 4. Влияние дополнительных занятий на успеваемость

### Результаты:

- С доп. занятиями: 32.48
- Без доп. занятий: 31.58
- Разница: +0.90 балла в пользу группы с доп. занятиями

### Статистическая проверка:

- t-test: p-value = 0.4180
- Тест Манна-Уитни: p-value = 0.2203

**Вывод:** Различия в успеваемости между группами **не являются статистически значимыми** ( $p > 0.05$  в обоих тестах). Наблюданное преимущество группы с дополнительными занятиями (+0.90 балла) может быть случайным.

## 5. Анализ пропусков занятий

### Корреляции:

- Пропуски и алкоголь: 0.139
- Пропуски и оценки: -0.006


### Сравнение групп:

- Частые пропуски: средний Salc = 4.23
- Редкие пропуски: средний Salc = 3.49
- теста Манна-Уитни p-value = \$0.0014 < 0.05\$

**Вывод:** Студенты с большим количеством пропусков потребляют больше алкоголя.


## 6. Семейные факторы


Корреляции семейных факторов с алкоголем и успеваемостью



## 7. Может быть профессия учителя у родителей помогает?

**Метод пристального взгляда:**





Для первых двух случаев данные ещё как-то можно считать нормальными, поэтому проверим на двух тестах.

*Без учителя vs хотя бы одним учителем:*

- Манна-Уитни: p-value = 0.06
- t-тест: p-value = 0.09

Нет оснований отвергнуть нулевую гипотезу о равенстве, следовательно, разница статистически не значима.

*Без учителя vs два учителя:*

Манна-Уитни: p-value = 0.004

С двумя учителями лучше.

## Описание статистических тестов

### Тест Манна-Уитни

- **Назначение:** Сравнение двух независимых выборок
- **Условия применения:** Отсутствие нормальности распределения, порядковые данные
- **Интерпретация:** Проверяет гипотезу о том, что одна выборка статистически больше другой

### t-тест для независимых выборок

- **Назначение:** Сравнение средних значений двух групп
- **Условия применения:** Нормальность распределения, гомогенность дисперсий
- **Интерпретация:** Проверяет гипотезу о равенстве средних

### Тест Шапиро-Уилка

- **Назначение:** Проверка нормальности распределения
- **Условия применения:** Размер выборки  $< 5000$
- **Интерпретация:** p-value  $> 0.05$  означает отсутствие оснований отвергать нормальность

### Тест D'Agostino

- **Назначение:** Проверка нормальности на основе асимметрии и эксцесса
- **Условия применения:** Подходит для больших выборок
- **Интерпретация:** Аналогично тесту Шапиро-Уилка

## Основные выводы

1. **Статус родителей** не оказывает значимого влияния на потребление алкоголя студентами
2. **Мужчины** потребляют значительно больше алкоголя, чем женщины
3. **Дополнительные занятия** не улучшают успеваемость
4. **Пропуски занятий** сильно коррелируют с повышенным потреблением алкоголя
5. **Семейные факторы** демонстрируют слабые корреляции с алкоголем и успеваемостью

Наибольшее практическое значение имеет связь между пропусками занятий и потреблением алкоголя, что может быть использовано для разработки профилактических программ.